

同濟大學

TONGJI UNIVERSITY

基于两层 ReLU 网络的曲线拟合实验报告

姓 名	石浩成 (2251189)
学院 (系)	计算机科学与技术学院
专 业	计算机科学与技术
指导教师	程大伟
日 期	2025 年 3 月 15 日

一、实验概述

理论和实验证明，一个两层的 **ReLU** 网络可以模拟任何函数。本实验的目的是利用两层前馈神经网络，对非线性函数 $y=\sin(2\pi x)+0.3x$ 进行拟合。

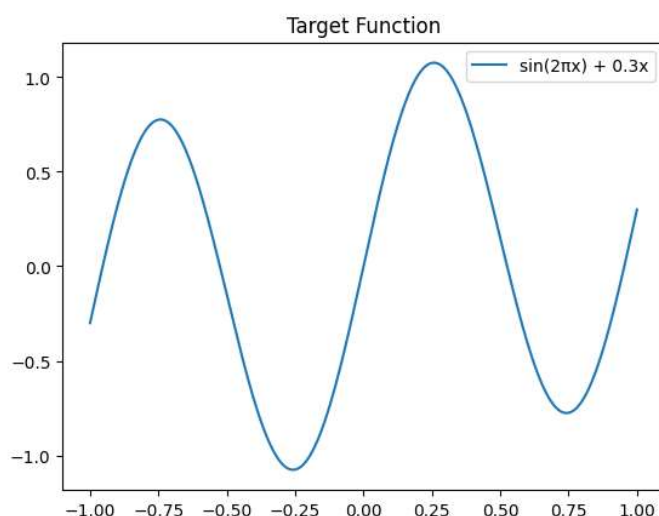
神经网络在函数拟合、模式识别和数据建模方面具有强大的能力。传统的线性回归方法对于复杂的非线性关系难以拟合，而深度学习方法能够通过多层神经元的组合，学习数据中的复杂模式，提高拟合精度。

本实验将构建一个两层神经网络，使用 **ReLU** 作为激活函数，并采用均方误差（**MSE**）作为损失函数进行优化。训练完成后，通过可视化手段评估模型的拟合效果，并分析其优缺点。

二、函数定义

目标函数定义为 $y=\sin(2\pi x)+0.3x$ ，并在区间 $[-1,1]$ 范围内采样数据。

```
def targetFunc(x):  
    """目标函数:  $y = \sin(2\pi x) + 0.3x$ """  
    return np.sin(2 * np.pi * x) + 0.3 * x
```



三、数据采集

使用 **NumPy** 生成数据，并划分为训练集、验证集和测试集。

```
x = np.linspace(-1, 1, 5000)  
y = targetFunc(x)  
  
X_train, X_test, y_train, y_test = train_test_split(x, y, test_size=0.2, random_state=1)  
X_train, X_val, y_train, y_val = train_test_split(X_train, y_train, test_size=0.125, random_state=1)
```

四、模型描述

本模型是一个两层神经网络，主要用于处理一维输入数据，并进行回归任务。模型的核心架构包括一个隐藏层和一个输出层，并采用均方误差 (MSE) 作为损失函数。

4.1 模型架构

输入层：输入维度为 1，即每个样本包含一个特征。

隐藏层：包含 16 个神经元，采用 ReLU 作为激活函数。

输出层：输出维度为 1，不使用激活函数，直接输出预测值。

4.2 模型参数初始化

(1) 权重初始化：

第一层权重矩阵 $W1$ 形状为 (16,1)，采用 $\text{np.random.randn}(\text{hidden_dim}, \text{input_dim}) * \text{np.sqrt}(1 / \text{input_dim})$ 进行初始化。

第二层权重矩阵 $W2$ 形状为 (1,16)，采用 $\text{np.random.randn}(\text{output_dim}, \text{hidden_dim}) * \text{np.sqrt}(1 / \text{hidden_dim})$ 进行初始化。

(2) 偏置初始化：

$b1$ 形状为 (16,1)，初始化为零。 $b2$ 形状为 (1,1)，初始化为零。

4.3 模型计算过程

(1) 前向传播过程如下：

- 第一层线性变换： $Z1 = W1 * X + b1$
- 激活函数 ReLU： $A1 = \text{ReLU}(Z1)$
- 第二层线性变换： $Z2 = W2 * A1 + b2$
- 输出结果： $y_{\text{pred}} = Z2$

(2) 损失计算方法：

损失函数采用均方误差 (MSE)，并存储梯度用于反向传播。

(3) 反向传播过程如下：

- 计算输出层误差 delta2 ，并计算 $dW2$ 和 $db2$ 。
- 计算隐藏层误差 delta1 ，仅对正梯度部分进行更新 (ReLU 的梯度特性)。

- 计算 $dW1$ 和 $db1$ 。
- 依据学习率 lr 对参数进行更新。

4.4 模型训练过程

本模型采用小批量梯度下降 (Mini-batch Gradient Descent) 进行训练。在每个训练轮次中, 将训练数据 X_{train} 和 y_{train} 划分成多个小批量, 对每个批次执行前向传播计算预测值 y_{pred} , 再计算损失并执行反向传播更新参数。训练过程中, 每隔 `verbose_ep` 轮输出损失信息, 方便观察训练进展。

训练超参数如下:

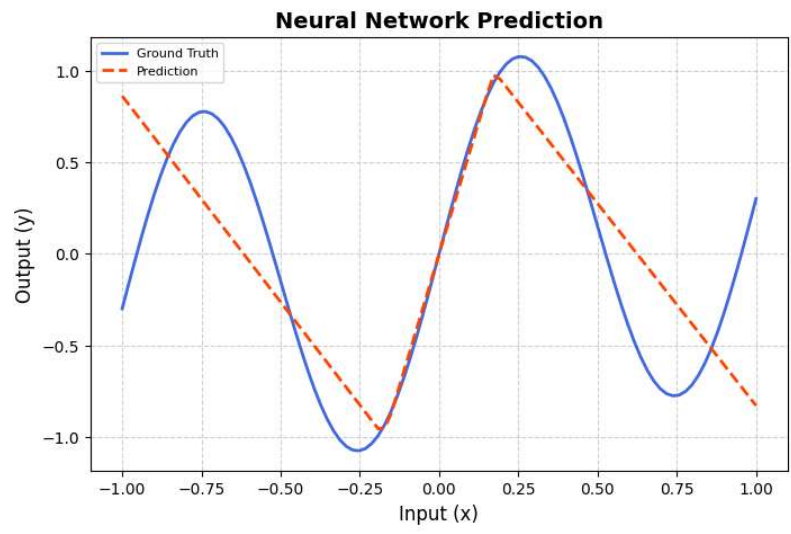
- 训练轮数: 5000
- 批量大小: 32
- 学习率: 0.01

五、拟合效果

训练完成后, 使用 `predict` 方法对模型的拟合效果进行可视化评估。测试过程中, 生成一定范围内的输入数据, 并利用训练好的神经网络计算对应的预测输出。最终, 通过绘制真实函数曲线(Ground Truth)与神经网络预测曲线 (Prediction) 进行对比, 以观察模型的拟合能力。

```
def predict(ranger):  
    """测试模型 & 可视化结果"""  
    x_plot = np.linspace(ranger[0], ranger[1], 100)           # 生成 100 个点  
    y_pred = np.array([forward(np.array([[i]])) for i in x_plot]).squeeze() # 计算预测值并压缩维度  
  
    plt.figure(figsize=(8, 5), dpi=100)  
    plt.plot(x_plot, targetFunc(x_plot), label="Ground Truth", color="royalblue", linewidth=2)  
    plt.plot(x_plot, y_pred, label="Prediction", color="orangered", linestyle="dashed", linewidth=2)  
  
    plt.xlabel("Input (x)", fontsize=12)  
    plt.ylabel("Output (y)", fontsize=12)  
    plt.title("Neural Network Prediction", fontsize=14, fontweight="bold")  
  
    plt.legend(loc="upper left", fontsize=8)  
    plt.grid(True, linestyle="--", alpha=0.6)  
  
    plt.show()
```

最终绘制出的可视化结果如下：



从图中可以看出，预测曲线与真实曲线的整体趋势相似，但未能很好地拟合复杂的波动模式，尤其是在函数的局部变化较大的区域（如极值点附近），表现出较大的偏差。这表明两层的 **ReLU** 网络虽然可以模拟任何函数，但在模拟相对复杂的函数时较为困难。

整体来看，目前的模型可以捕捉数据的全局趋势，但在局部拟合上仍有较大提升空间。改进方案有：增加隐藏层神经元数量（例如从 16 个增加到 32 或 64 个），增强模型的表达能力；增加训练轮数，例如从 5000 轮增加到 10000 轮，以充分训练模型；调整学习率，可能当前学习率过大或过小，影响收敛速度和最终性能。